

Nama : ARDIUS EBENEZER SIMANJUNTAK

NIM : 1103210208

KELAS : TK-45-G04

ANALISA LAPORAN

Penggunaan kompleksitas Model yang menunjukkan bahwa model deep learning sangat dipengaruhi oleh kombinasi parameter yang dipilih. Variasi jumlah hidden layer, neuron, fungsi aktivasi, learning rate, epoch, dan batch size memiliki dampak signifikan terhadap performa model klasifikasi.

Pemilihan Fungsi Aktivasi yang memainkan peran kritis dalam performansi model. Dalam eksperimen ini, Rectified Linear Unit dan Sigmoid cenderung menunjukkan hasil yang lebih baik dibandingkan fungsi aktivasi lainnya. Hal ini konsisten dengan penelitian sebelumnya yang mengungkapkan keunggulan ReLU dalam menangkap kompleksitas non-linear data.

Hyperparameter Tuning dalam memproses pencarian hyperparameter yang sistematis sangat penting. Learning rate yang tepat (berkisar antara 0.01 hingga 0.001) memperlihatkan konvergensi model yang lebih stabil. Jumlah epoch antara 50-100 umumnya memberikan keseimbangan optimal antara learning dan overfitting.

Arsitektur Model dengan ukuran 2-3 hidden layer dan rentang neuron antara 16-64 menunjukkan performa paling konsisten. Hal ini mengindikasikan bahwa kompleksitas model perlu diseimbangkan - tidak terlalu sederhana namun juga tidak berlebihan, serta berbagai Batch Size antara 32-128 memperlihatkan stabilitas tertinggi dalam proses training. Batch size yang terlalu kecil menyebabkan estimasi gradient yang tidak stabil, sementara batch size yang terlalu besar dapat mengurangi kemampuan model untuk mengadaptasi variasi data. Meskipun menggunakan dummy data, metodologi eksperimen ini dapat diterapkan pada berbagai dataset dengan melakukan penyesuaian parameter sesuai karakteristik data spesifik.

Rekomendasi Praktis digunakan dengan selalu lakukan eksperimen sistematis dengan berbagai kombinasi parameter, teknik cross validation untuk validasi model, mempertimbangkan kompleksitas komputasi dan waktu training dan dokumentasikan hasil eksperimen untuk referensi penelitian selanjutnya.

Keterbatasan dihasilkan dengan hasil bergantung pada dataset dummy, komputasi yang intensif dan tidak menjamin performa maksimal pada semua jenis data apapun.

Penggunaan model MLP ini bertujuan untuk mengevaluasi pengaruh berbagai kombinasi hyperparameter terhadap performa model Multi-Layer Perceptron (MLP) yang diterapkan pada dataset Abalone. Kami menguji beberapa hyperparameter utama, yaitu jumlah hidden layers, fungsi aktivasi, learning rate, batch size, dan jumlah epoch. Untuk mempercepat pencarian, eksperimen dilakukan dengan pendekatan randomized search, di mana kami memilih kombinasi acak dari berbagai nilai hyperparameter dan mengevaluasi hasilnya berdasarkan akurasi model.

Berdasarkan hasil eksperimen, pengaruh jumlah hidden layers terhadap performa model tersebut sangat signifikan. Model yang menggunakan lebih dari satu hidden layer, seperti kombinasi [16, 32, 64], menunjukkan performa yang lebih baik daripada model dengan satu hidden layer seperti [4] atau [8]. Hal ini menunjukkan bahwa model dengan lebih banyak layer tersembunyi memiliki kapasitas lebih besar untuk menangkap pola-pola yang lebih kompleks dalam data. Sebaliknya, model dengan sedikit layer tersembunyi cenderung memiliki akurasi yang lebih rendah karena keterbatasan dalam menangani kompleksitas data.

Selain jumlah hidden layers, fungsi aktivasi juga berperan penting dalam menentukan performa model. Fungsi aktivasi ReLU terbukti memberikan hasil yang paling optimal di antara semua yang diuji. ReLU membantu menghindari masalah vanishing gradient yang sering terjadi pada fungsi aktivasi lain seperti Sigmoid atau Tanh, yang membuat pelatihan model dengan kedalaman lebih besar menjadi lebih lambat dan sulit konvergen. Fungsi aktivasi Identity tidak memberikan perubahan signifikan pada output neuron, sehingga model dengan fungsi ini cenderung menghasilkan akurasi yang lebih rendah karena tidak memberikan non-linearity yang dibutuhkan untuk pembelajaran yang efektif.

Pengaruh learning rate terhadap performa model juga cukup jelas. Nilai learning rate yang lebih kecil, seperti 0.001 atau 0.0001, cenderung menghasilkan akurasi yang lebih baik, terutama pada model yang dilatih dalam jumlah epoch yang lebih banyak. Learning rate yang lebih kecil memungkinkan model untuk melakukan konvergensi dengan lebih stabil, menghindari lonjakan besar dalam pembaruan bobot yang dapat menyebabkan model tidak stabil atau gagal menemukan solusi yang optimal. Sebaliknya, learning rate yang besar, seperti 10 atau 1, sering kali mengarah pada konvergensi yang cepat, tetapi tidak mencapai akurasi terbaik karena pembaruan yang terlalu besar menyebabkan model kehilangan titik optimal.

Batch size juga mempengaruhi kinerja model, dengan batch size yang lebih besar seperti 128, 256, atau 512 cenderung menghasilkan hasil yang lebih baik. Penggunaan batch size yang besar memberi model lebih banyak data untuk diproses dalam setiap iterasi, yang membantu mempercepat konvergensi dan meningkatkan kestabilan pelatihan. Sebaliknya, batch size yang kecil seperti 16 atau 32 dapat memperlambat proses pelatihan karena model perlu melakukan lebih banyak pembaruan bobot untuk setiap epoch, yang mungkin menyebabkan fluktuasi dalam gradien dan mengurangi akurasi.

Model dengan jumlah epoch yang lebih tinggi, seperti 100 atau 250 menghasilkan akurasi yang lebih tinggi. Hal ini menunjukkan bahwa model membutuhkan lebih banyak waktu untuk belajar dan mengoptimalkan bobotnya agar dapat mencapai performa terbaik. Model yang hanya dilatih selama 1 atau 10 epoch biasanya memiliki akurasi yang lebih rendah karena belum cukup waktu untuk mempelajari pola dalam data secara mendalam.

